

I / O F U N D · 深度研究

Beth Kindig 2026 上半年 AI 产业与投资深度分析报告

半导体 · 存储超级周期 · 超算基建 · 大模型军备竞赛

分析对象：Beth Kindig (@Beth_Kindig) / I/O Fund

数据区间：2026 年 1 月 — 6 月

素材范围：5 篇 Newsletter 摘要 + 485 条推文时间线

分析维度：宏观泡沫之争 · 算力芯片 · 存储 · 基建 · 大模型

报告日期：2026 年 7 月

本报告为基于公开文本素材的研究性整理，所有数据与结论均直接引用或基于原始素材中的财报指导、机构预测与新闻事件。

仅供研究参考，不构成任何投资建议。市场有风险，投资需谨慎。

目录

1. 宏观市场与"AI 泡沫"之争
2. 算力与芯片竞争格局演进 (GPUs / CPUs / ASICs)
3. 存储超级周期 (The Memory Supercycle)
4. 基础设施：能源、网络与 Neoclouds
5. 大模型初创巨头的军备竞赛：OpenAI vs. Anthropic
6. 结论与前瞻

一、宏观市场与"AI 泡沫"之争

1.1 宏观走势预判：从"防守转向"到"顶部构筑"

作者对 2026 年大盘的核心判断是 "高波动中的结构性牛市，但需高度警惕轮动见顶信号"。

- **2025 收官基准**：纳斯达克 100 +20.2%、标普 500 +16.4%、道指 +13%，而费城半导体 ETF \$SMH 大涨 49.2%。摩根大通指出，AI 股票贡献了标普 500 全年涨幅的约 70%。
- **顶部构筑警告（自 2025 年 10 月起）**：作者与联合基金经理 Knox Ridley 明确提示，市场自去年 10 月起进入 "多月度筑顶过程"。领先信号链条清晰：
 - **比特币 \$BTC 与高 Beta 股率先见顶**——自 8 月预警后 \$BTC 重挫近 48%；
 - **"Magnificent 7" 出现分化**——七巨头中已有 六只相对大盘走弱。
- **关键技术点位**：2 月划定标普 500 的 6,780 为 "沙线"，警告跌破将下探 6,300；市场实际在 6,316 见底后反弹，4 月成为纳指 100 六年来最佳单月。
- **半导体背离警报**：作者引用 "2023 年 5 月以来的经验法则"——**每当半导体创新高而英伟达不确认，即为危险信号**。5 月 \$SMH 较 10 月高点上涨逾 30%，而 \$NVDA 反跌 4%，据此 I/O Fund 一度将英伟达仓位 "移至场外观望"。
- **市场集中度风险**：标普 500 中 33 家半导体公司占指数权重约 18%，是互联网泡沫顶峰时的两倍多；且五只半导体股（NVDA、MU、AVGO、AMD、INTC）驱动了标普今年过半涨幅——高度集中意味着高脆弱性。

1.2 反驳"AI 泡沫论"的核心论点

作者是坚定的 "非泡沫" 派，论证建立在 **历史周期、估值实证与货币化闭环** 三大支柱上：

1. **历史类比——"狼来了" 十年**：自 2015 年以来 "科技泡沫" 警告从未停歇，同期 纳斯达克 100 上涨 550%。多数被误判为 "泡沫" 的时刻实为 **正常的市场重置**。
2. **估值实证——龙头反而 "更便宜"**：关键反直觉数据——**英伟达当前 PE 已接近 2025 年 4 月低点与 2022 年 10 月底水平**，尽管过去五年股价上涨 1,390%。
3. **货币化闭环将对冲 Capex**：泡沫论者假设 "推理货币化浪潮无法覆盖投资"，作者反驳——**推理 (Inference) 的爆发正是买单方**，佐证包括 Big Tech 的巨额自由现金流与指数级 token 处理量。
4. **需求刚性**：Ecolab 高管名言——**"无论是一个大泡沫还是许多小泡沫破裂，整体需求曲线都将继续向前。"**

宏观小结：作者立场是 "长期看多 AI 主线，短期警惕大盘轮动见顶"——泡沫论证伪，但过度集中的市场结构要求投资者用技术面严守纪律。




图 1 三大超算厂商 2026 资本支出指引：Amazon ~\$200B、Alphabet \$175–185B、Meta \$125–145B

数据来源：各公司财报电话会 / Goldman Sachs (Beth Kindig 推文摘录)

二、算力与芯片竞争格局演进（GPUs / CPUs / ASICs）

2.1 英伟达的双面性：无可争议的巨头，却未必是 2026 最优标的

多头面（通往 20 万亿市值的路径）

- **架构推进**：Rubin 平台**已满产**，芯片 2H 2026 上市。规格碾压——Rubin 的 NVFP4 推理性能达 50 PFLOPs、训练 35 PFLOPs，分别为 Blackwell 的 5 倍与 3.5 倍；推理 token 成本再降 10 倍，训练 MoE 模型所需 GPU 减少 4 倍。Vera Rubin NVL72 单机架带宽 260TB/s，超过整个互联网。
- **现金流碾压**：FY27 自由现金流预计 >1,580 亿美元（FY26 约 970 亿），是 2023 年 38 亿的 40 倍以上。FY23—FY27 累计 FCF 约 3,500 亿美元，是博通的 2 倍、AMD 的 12 倍。BofA 预计 2026—2027 两年 FCF >4,000 亿美元，超过苹果、Meta、亚马逊、谷歌四家之和。
- **业绩验证**：Q1（5 月报）营收 816 亿美元（+85.2%），数据中心 752 亿（+92%），网络业务 +199% 至 148 亿；Q2 指引 910 亿（+94.7%）。GTC 披露 2027 年前 1 万亿美元 AI 芯片可见度，Vera Rubin 可使 GW 级数据中心 token 生成量提升 350 倍。
- **市值愿景**：黄仁勋称能达 10 万亿，作者更激进地喊出 20 万亿，认为“通往 20 万亿的路径比 2020 年通往 1 万亿更现实”。

空头面（为何 2026 未必是“最佳风险/回报”）

作者 4 月明确指出（“投资的本质是机会成本”），三条逻辑构成风险：

1. 定制硅片（Custom Silicon）持续蚕食份额；
2. CUDA 护城河在推理时代重要性下降；
3. Rubin 存在延迟风险——KeyBanc 指出 Rubin 因 HBM4 认证问题小幅延迟；CoWoS 2026 供应维持 650K 不变，成为潜在瓶颈。

2.2 CPU 预算争夺战：Agentic AI 让 CPU“王者归来”

本期最核心的新叙事。作者判断：过去三年聊天机器人靠 GPU“挑大梁”，但 Agentic AI 是 2026 年后最大催化剂，正让 CPU 重要性回归，CPU:GPU 配比正走向 1:1。

- **市场规模爆炸**：UBS 测算 服务器 CPU TAM 从 2025 年 310 亿美元飙升至 2030 年 1,700 亿美元，其中 AI CPU 从 70 亿暴增至 1,250 亿。
- **AMD**：x86 服务器 CPU 份额 Q4 首破 40%（41.3%）；且 33.2% 的销量却拿下 46.1% 的收入，定价权强于英特尔。Meta 成为其六代 EPYC “Venice”/“Verano”首发客户。

- **Arm**: 推出自研 "AGI CPU" (136 个 Neoverse 核心), 单机架性能达 x86 两倍, 每 GW 数据中心节省 100 亿美元 Capex。Meta 首发, ByteDance、Oracle 跟进; CEO"非常有信心"2030 年达成 150 亿美元营收目标。
- **Intel**: 新 CEO Lip-Bu Tan 主导, 与富士康合作全 Xeon 机架; 18A 制程获英伟达测试。
- **Nvidia (Grace/Vera)**: 与 Meta 达成首个大规模 Grace 部署, Vera CPU 已交付 Oracle、SpaceX、Anthropic、OpenAI, Oracle 计划部署数十万颗。
- **Amazon Graviton**: Graviton5 已 GA; 芯片业务运行率达 200 亿美元, Meta 签约使用"数千万核"。
- **价格信号**: Intel/AMD 的 CPU 价格环比上调 10%—35%。




图 2 服务器 CPU 总 TAM 五年增长约 5.5 倍, AI CPU 更是从 70 亿暴增至 1,250 亿美元

数据来源: UBS (Beth Kindig 推文摘录, 2026-05-28)

2.3 超算巨头自研芯片 (ASICs): 云厂商的"去英伟达化"

ASIC 服务器市场份额从 2025 年约 21% 升至 2026 年约 28%; Counterpoint 预计 2024—2028 年前十大超算厂商累计出货 4,000 万颗 AI ASIC。

云厂商	自研芯片	关键进展与数据
Google	TPU 8t / 8i	8t 性价比较 Ironwood 提升 2.7 倍 ； 开始向第三方销售 TPU ；UBS 预计出货 2026 年 413 万 → 2027 年 987 万颗；占 Alphabet AI 服务器 78% ；与 Blackstone 合资（后者投 50 亿）。
Amazon	Trainium2/3/4	积压订单 2,250 亿美元 ，Trainium2 已售罄；自称"每年省下数百亿 Capex"；考虑对外销售。
Meta	MTIA 300—500	300 已部署、400 完成测试；450 优化推理，HBM 带宽 18.4TB/s；与博通合作共同开发（>1GW）。
Microsoft	Maia 200	FP4 性能为亚马逊 Trainium3 的 3 倍 ，性价比较上代提升 30%。
OpenAI+博通	Jalapeno	首款推理优化芯片，"每瓦性能显著优于当前最先进芯片"。

最大赢家是博通 (\$AVGO)：UBS 预计其 AI 收入 **FY26 约 600 亿 (+200%) → FY27 1,060 亿 → FY28 1,500 亿**，2027 年出货 500 万颗 TPU。

2.4 晶圆代工与先进封装：台积电的"卖方定价权"

- **产能瓶颈即定价权**：TSMC 先进制程 **2026 年涨价 3%—10%**，并逐年提价至 **2029 年**。博通高管直言"台积电已触及产能极限，成为 **2026 年供应链的瓶颈**"。
- **制程路线图**：2nm 已量产；**1.4nm 试产提前至 2027 年、量产 2028 年**；3nm 月产能年底目标 180K。
- **CoWoS 先进封装**：高盛预计年产能 **2025—2027 从 67.5 万片三倍增至 231 万片**；供需缺口从约 20% 收窄至年底约 10%。
- **业绩与展望**：FY25 营收 **1,224 亿美元 (+35.9%)**，HPC 占比 58%；**AI 加速器 5 年 CAGR 上调至 50% 中高段**；预计 2030 年全球芯片市场达 **1.5 万亿美元**。英伟达 2026 年将占 TSMC 营收 **20% 以上**。
- **追赶者**：三星 2nm 良率超 60%，目标 2030 年 1nm；Intel 代工获谷歌 300 万颗 TPU（2028）；SK 海力士下单 **80 亿美元 EUV**。

三、存储超级周期（The Memory Supercycle）

3.1 供需失衡与"长牛至 2030"逻辑

存储是本期文本中**共识最强、涨幅最猛**的赛道。行业高管**罕见地口径一致**看到 2030 年：

- **SK 集团会长 Chey Tae-won**：全球存储晶圆短缺 **可能持续至 2030 年**，缺口时有超 20%。
- **Intel CEO Lip-Bu Tan**（转述三大厂）："直到 2028 年都没有缓解。"
- **Micron**："需求远高于全行业供给能力.....紧张将持续到 2026 年以后。"
- **Samsung**："仅基于目前 2027 年已收到的需求，2027 年供需缺口将比 2026 年进一步扩大。"

根本原因：HBM 挤占常规产能。摩根士丹利测算 **仅纯文本 AI 推理就将占 2026 年全球 DRAM 供给的 35%、NAND 的 92%**。AI 相关需求 2027 年将占 DRAM 需求 75% 以上。副作用是 **PC 价格 Q2 涨 25%—30%**。

3.2 市场规模激增：核心数据

定价涨幅（惊人）

- 三星/SK 海力士 Q1 服务器 DRAM 报价上调 **60%—70%**；
- Citi 预测 **2026 年 DRAM 均价 +88%，服务器 DRAM +144%**；
- HBM 需求 2026 年 +70%。

市场规模（TrendForce 口径一路上修）

- 全球存储市场：初预测 2026 年 +134% 至 5,516 亿 → 6 月上修至 **8,893 亿美元 (+296% YoY)**；**2027 年 1.28 万亿美元**——是 2025 年 (2,247 亿) 的 **5 倍以上**。
- WSTS：2026 年存储 +250% 至 8,039 亿（占半导体市场 53%+），**2027 年存储突破 1 万亿美元**。

HBM 迭代

- **HBM 占 AI 芯片物料成本从 2024 Q1 的 <52% 升至 63%**；
- HBM4 份额 **2026 年 27% → 2027 年 53%**；
- 三家 HBM4 **均已通过英伟达认证并投产**；SK 海力士锁定英伟达 Vera Rubin **70% 的 HBM 订单**。

全球存储市场规模：两年 5 倍级"超级周期"

单位：十亿美元（TrendForce 预测）




图 3 存储市场从 2025 年 2,247 亿美元，激增至 2026 年 8,893 亿、2027 年 1.28 万亿美元

数据来源：TrendForce（Beth Kindig 推文摘录，2026-06-08 / 06-09）

利润逆转：SK 海力士 Q1 营业利润率 **72%**；三星、SK 海力士 2026 年利润预计双双超越 TSMC。Micron FQ3 营收 **414.6 亿美元 (+345.8%)**，营业利润率超 80%；**10 个月内市值增长逾 1 万亿美元**，回报跑赢英伟达 18 倍。

四、基础设施：能源、网络与 Neoclouds

4.1 能源与电力瓶颈：AI 的"物理天花板"

作者的核心判断："AI 经济的真正风险不在算力供给，也不在软件能力，而在电力供给与散热基础设施。"

- **需求冲击**：AI 训练/推理用电 **44GW (2025) → 155GW (2030)**；数据中心用电占全美比例从 4—5% 升至 **9%—17%**（弗吉尼亚州将从 25% 飙至 39%—57%）。微软 Fairwater Wisconsin 单体达 **3.3GW**、耗资 **1,060 亿美元**。
- **电网瓶颈**：亚马逊欧洲扩张受阻于 **长达 7 年的并网周期**；电网容量"基本已被预订至 2030 年"，倒逼**自备电源**。
- **破局路径**：核能（Meta 锁定 **6.6GW**）、地热（谷歌 Ormat）、天然气（Chevron 为微软 Pecos 建 2.67GW 自备电站）。
- **燃料电池（重点：Bloom Energy \$BE）**：作者 **连续两年的年度首选股**，主打"time-to-power"这一最紧迫瓶颈。与 Oracle 扩约 **2.8GW 燃料电池**；股价**自首次建仓上涨约 1,100%—1,600%**，从 \$16.64 涨至 \$155.60。

4.2 网络与 CPO 演进

作者反复强调："规模化扩展 AI 的最难点不是造更快的芯片，而是可靠地把它们连起来。"

- **CPO（共封装光学）是最大结构性变革**：渗透率从 **2025 年 <0.1% 跃升至 2030 年 >35%**。英伟达 **斥资 40 亿美元** 锁定 CPO 供应链，2027—2028 放量。
- **光模块供给紧张=定价权**：Lumentum **供货缺口 >30%**；Meta 向康宁承诺 **60 亿美元光纤**。
- **英伟达网络霸权**：已成为**数据中心以太网交换市场收入第一**；谷歌 A5X 单站点连接 8 万颗 Rubin、多站点达 96 万颗。

4.3 算力租赁新贵（Neoclouds）：狂飙与隐患并存

扩张速度惊人（Q1 2026 营收同比增长 2 倍至 7 倍）：

- **CoreWeave \$CRWW**：营收积压近 **1,000 亿美元**，2026 产能"基本售罄"；与 Meta 签约 **210 亿美元（至 2032）**；获英伟达 20 亿投资。



- **Nebius \$NBIS**: Meta 五年 120 亿; 获英伟达 20 亿投资、2030 年前部署 5GW。

作者明确警示的两大风险:

1. **循环融资 (Circular Financing)**: 英伟达投资客户 → 客户回购英伟达 GPU, 形成自我强化的资金闭环。
2. **高杠杆债务**: AI 相关债券发行 2026 年或翻倍至 **5,700 亿美元**; 相较超算巨头, Neoclouds 缺乏资产负债表优势。

五、大模型初创巨头的军备竞赛：OpenAI vs. Anthropic

2026 上半年最震撼的对决——两家公司估值均逼近甚至突破 1 万亿美元，收入以“每季翻倍”速度狂奔。



维度	OpenAI	Anthropic
年化收入	\$20B+ (2025末) → \$24—25B (\$2B/月)	\$9B → \$14B → \$19B → \$30B → \$47B (2025末至5月)
收入预测	2029 目标约 \$146B	2026 \$18B → 2027 \$55B → 2029 \$149B (反超 OpenAI)
估值	\$500B → \$852B	\$183B → \$965B (反超 OpenAI)
融资记录	\$122B 单轮 (软银\$30B、英伟达\$30B、亚马逊\$50B)	\$65B (拟 10 月 IPO)
Token/用量	周活 9 亿 ；API 150 亿 token/分钟	Claude Code 运行率 \$25 亿 , "编写公司 90% 代码"
算力扩张	1.9GW → 10GW+ → 2030 年 30GW	1.4GW → 7—8GW (多云+自研)
Capex/支出	2026 约 \$50B, 2030 前累计 \$600B	Q2 首现营业利润 \$5.59 亿

关键结构性看点：

- **合计资本消耗**：WSJ 估算两家 **2026 年合计烧钱约 650 亿 → 2027 年 1,270 亿 → 2029 年近 2,500 亿美元**——这正是上游芯片/存储/能源需求的"终极买单人"。
- **多云 + 自研双轨**：Anthropic 按工作负载匹配 AWS Trainium、Google TPU、Nvidia GPU；OpenAI 与博通推出 Jalapeno 自研推理芯片。
- **货币化提速**：OpenAI 广告业务两个月做到 \$1 亿 ARR，预计 2027 年 \$110 亿；企业收入已占 40%+。

结论与前瞻

确定性最高的赢家赛道，是"卖铲人"链条中受物理产能约束、拥有定价权的环节——以"存储超级周期（HBM/DRAM）"为最强主线，叠加"电力/时间-通电（Bloom Energy 为代表）"与"光互联/CPO"两大瓶颈受益者。

逻辑在于：三大厂罕见一致预警短缺延续至 2030 年、存储市场规模两年内从 2,247 亿膨胀至 1.28 万亿美元、SK 海力士 72% 的利润率与 Micron +345% 的营收，共同证明这是一个由**刚性供需失衡而非情绪驱动**的、可用财报逐季验证的确定性行情；而 CPU 因 Agentic AI 从"配角"变"下一大瓶颈"（TAM 五年增 5.5 倍），是最值得关注的第二增长极。

最大潜在风险点则是"循环融资 + 高杠杆债务"叠加"大盘轮动见顶"的共振——英伟达投资 Neoclouds 与大模型公司、后者再回购其 GPU 的资金闭环，一旦遇到电力/散热的物理天花板迟迟无法突破、或 AI 债券发行（2026 年或达 5,700 亿）遭遇利率与流动性收紧，将成为引爆估值回调的第一张多米诺骨牌；这也正是作者一边高喊英伟达 20 万亿、一边将其仓位"移出场外"的深层原因——**看多产业长期趋势，但对 2026 年的高集中度市场结构保持技术面纪律。**