

Jamin Ball (Altimeter) 内容深度拆解

科技巨头基本面与算力周期投研报告

数据边界说明： 本报告全部量化指标源自 Jamin Ball 2026 年 1-7 月的 Newsletter 与推文时间线 ([digest_jaminball.md](#))。涉及型号 (H100 / H200 / GB200 / GB300)、模型 (GLM5.2、Luna、KARL、Claude 4.6、GPT 5.2)、公司 (Colossus / SpaceX 算力、Reflection、Marin) 均以原文口径为准。核心投资标的映射：\$MSFT、\$GOOG、\$AMZN、\$NVDA。

1. 算力基础设施与"新云 (Neocloud)"经济学

1.1 GPU 定价：从"按小时"到"按 Token"的计费范式迁移

原文提供了两组可交叉验证的硬件租金数据，构成本报告最硬核的量化基石。

(A) xAI Colossus 1 单机集群经济模型 (2026-05-06 口径)

芯片架构	集群数量 (假设)	租赁单价 (\$/GPU·小时)
H100	150,000	\$2.30
H200	50,000	\$2.60
GB200	20,000	\$5.00
全集群混合价	220,000	\$2.60

在 take-or-pay (24x365 全额付费) 结构下，该集群折算 **约 \$50 亿/年营收**——"我们诞生了一个新云 (a new neocloud)"。

(B) SpaceX 三笔 Neocloud 合约的定价断层 (2026-06-22 口径)

交易对手	集群	月度合约额	芯片规模	混合小时租金
Anthropic	Colossus 1+2	\$1.25B/月	约 325k (150k H100 / 50k H200 / 125k GB200)	约 \$5—6/小时
Google	Colossus 2	\$920M/月	约 110k (GB200/GB300 未明)	约 \$11—12/小时
Reflection	Colossus 2	\$150M/月	约 18k GB300	按 Google 口径反推
合计	—	\$2.32B/月 (约 \$27.8B 年化)	—	Blackwell >\$10/小时

投资含义（对 \$NVDA 护城河的暗示）：

- **代际租金溢价 = Nvidia 定价权的市场化确认。** 从 Hopper (H100 \$2.30) → Blackwell (GB200 \$5、GB300 隐含 >\$10/小时) **租金翻了 4 倍以上**。这说明下游 Neocloud 愿意为新架构支付陡峭溢价，直接支撑 Nvidia 每代产品的 ASP 阶梯式上移；护城河体现在“新硬件更贵，且仍供不应求”（2026-06-05: "More recent hardware costs more!"）。
- **计费范式迁移是二阶催化剂。** 原文核心论断（2026-03-27）：“Per GPU hour 定价属于训练主导（GPU 是成本中心）的世界；转向推理驱动（营收驱动）后，将出现 per-token / 基于 credit 的计费。”算力价值从“卖铁”（按小时）迁移到“卖产出”（按 Token）——谁能卡进 **token path**（2026-05-22: "Gotta get in the token path!"）谁就获得定价权。

1.2 电力与规模瓶颈：“Time to Power”与 GDP 级资本开支

原文 6 月 26 日 Newsletter 主题即 **"Time to Power"**，并在 2026-06-02 推文给出关键量化：

- **1GW 数据中心单位 CAPEX：**Jamin 原估 **约 \$50B/GW**；黄仁勋（Jensen）2026 年 6 月上调至 **\$80—100B/GW**。
- **总量测算（取 OpenAI 计划外推全市场）：**未来约 5 年新增 **150GW** → 按 \$50B/GW = **约 \$7.5 万亿总支出 = 年 GDP 的约 5%**。
- **历史对标：**略低于 1800 年代末铁路大建设的 **约 6% GDP**。
- **上行风险情景：**若单位成本升至 \$80—100B/GW，则整体支出将逼近 **年 GDP 的约 10%**，"truly unprecedented（史无前例）”。

核心物理与金融约束：

1. **金融约束（债务偿付时钟）：**数据中心多以债务融资（数十亿至数百亿），债权人核心问题是“借款方何时、以多大概率能还款”→ 取决于 **cash register 何时开始响**（何时能通电产生收入）。因此 **"Time to Power"（通电时间）直接决定项目融资可行性**，成为比芯片供应更硬的瓶颈。
2. **物理约束：**电力接入、供应链、物理劳动力上限、信贷上限。
3. **宏观脆弱性：**“如此多的 GDP 增长押注在 AI 数据中心建设上……一纸数据中心禁令（moratorium）就可能对经济造成巨大冲击。”——这是对 **整个 AI 资本开支主题系统性下行风险**的明确警示。

投资含义： 电力从"配套"升级为**估值定价的核心变量**。利好自建电力/HVDC 电网标的（原文点名 @am_watt 的 HVDC 电网、@basepowerco）；对超大厂而言，**能拿到电、拿到并网时点的一方将赢得算力军备竞赛**，重构了 \$MSFT/\$GOOG/\$AMZN 的相对优势排序。

1.3 新云崛起：SpaceX 效应与对公有云的冲击

- **"人人都在变成 Neocloud" (2026-05-28)：** "You either die an AI loser, or live long enough to become a neocloud. Everyone is becoming a neocloud!"
- **SpaceX 作为体制外算力供应商：** 单月 \$2.32B 合约、325k+ 芯片规模，已具备与二线公有云匹敌的体量。
- **关键结构性特征——短期合约风险：** SpaceX 三笔交易**均为短期合约**，双方各有 **90 天退出权**。这是一把双刃剑：
- **上行叙事：** 结合 5.29 "Second Life of a GPU"——若芯片在 4-5 年使用寿命后仍保值，Neocloud 单位经济学将"surprise people"。
- **威胁的证伪点：** 90 天可退出意味着**客户黏性极低、收入可预测性差**；在长约与生态锁定层面，\$MSFT/\$GOOG/\$AMZN 仍具结构性优势。

2. 云巨头基本面与 AI 变现追踪

2.1 三大云营收运转率与增速对比

报告季 T-1 (2026 年 1 月底—2 月初披露)：

厂商	Run Rate	YoY 增速	环比上季
AWS (\$AMZN)	约 \$142B	24%	上季 20% (加速)
Azure (\$MSFT)	约 \$103B (估)	38% cc	上季 39% (微降)
Google Cloud (\$GOOG, 含 GSuite)	约 \$71B	48% YoY	上季 34% (HUGE jump)

报告季 T (2026-04-29 披露)：

厂商	Run Rate	YoY 增速	环比上季
AWS (\$AMZN)	约 \$150B	28%	上季 24% (加速)
Azure (\$MSFT)	约 \$108B (估)	39% cc	上季 38% (加速)
Google Cloud (\$GOOG)	约 \$80B	63% YoY	上季 48% (又一次 MASSIVE jump)

关键投研结论：

1. **Google Cloud 是加速度之王**。两季连续大幅跳升（34% → 48% → 63%），且在最大基数扩张的同时增速反而抬升，是三家 AI 拉动信号最强、最具重估潜力的资产（\$GOOG 云业务重估催化剂）。
2. **AWS 触底反弹**。从 20% → 24% → 28% 连续两季加速，扭转此前的市占率流失担忧，\$AMZN 云叙事修复。
3. **Azure 体量最稳、增速最高台阶**。约 \$108B 规模上仍维持 38—39% cc 且小幅加速，绝对增量金额领先，\$MSFT 变现确定性最高。
4. **AI 变现的实证**：三家在万亿级 run rate 基数上同步加速，是"AI 需求真实拉动云业务"最直接的宏观证据。

2.2 模型与开源生态：Open-weight vs Open Development

(A) 四段式开放光谱（2026-05-29, Percy Liang / Marin / OpenAthena）:

闭源(API-only) → 开放权重(Llama, DeepSeek) → 开源(OLMo, Nemotron) → 开放开发(Marin)

- **"Open development > open weights"**：多数"开放"模型只交付权重；Marin 暴露**全过程**——权重、代码、数据配方，以及"活的研究本身"（任何人/任何 agent 都能像给 Linux 提 PR 一样提交实验）。
- **可量化的科学性指标**：预注册预测 loss 到 GitHub 后验证，在拟合点 300 倍 FLOPs 处误差仅约 0.005 loss (MoE 上约 0.02, 无 spike)。
- **算法效率定律**： $accuracy = algorithmic\ efficiency \times resources$ ，且 LM 效率每约 8 个月使所需算力减半。

(B) 闭源模型成本断崖（2026-06-26）:

模型	输入价 (\$/1M tokens)	输出价 (\$/1M tokens)	混合价
GLM5.2	\$1.40	\$4.40	\$2/1M
Luna	与 GLM5.2 持平	与 GLM5.2 持平	\$2/1M

对底层算力需求的二次刺激分析：

- 表面上，GLM5.2/Luna 的"frontier by way cheaper"（前沿性能、价格腰斩）似乎利空算力需求。
- 但结合"效率每 8 个月减半"定律 + **杰文斯悖论 (Jevons Paradox)**：单位 Token 成本断崖式下降 → 应用侧调用量爆炸式增长 → **总 Token 消耗 (=总算力需求) 不降反升**。这正是 2.1 节"从按小时到按 Token 计费"的需求侧引擎。
- **关键方法论提醒 (2026-06-26)**："大家都在谈 GLM5.2 多便宜，却没人讨论它的 **token 效率**。"便宜的单价若伴随冗长推理链（消耗更多 token），实际总成本未必低。OpenAI 的应对是将性能同时对 cost 与 latency 作图（性能/美元、性能/秒）。
- **投资含义**：成本下降 → 需求放大 → **对 \$NVDA 与超大厂算力是净利好**；同时利好推理优化层（原文投资标的 @inferact / vLLM 系）。

2.3 Dario 单位经济学（行业口径，2026-05-06）

- 取 \$100B 算力支出，当前行业 **训练/推理 约 50/50**。
- **\$50B 推理支出 → 可转化为 \$150B 营收**（1–2 年内的行业单位经济学）。
- 套用 xAI 案例：Anthropic 年付 \$5B → 有望产生 **\$15B/年营收（60–70% 毛利率）**。
- **平衡术**：过度偏训练则收入不足；过度偏推理则牺牲未来 R&D 进展。

这是把"Capex 军备竞赛"翻译成"可回收现金流"的关键桥梁——约 3 倍的推理支出→营收放大倍数，为整个算力主题提供 ROI 可行性证明，缓解市场对"Capex 无底洞"的担忧。

3. 软件范式转移：从 SaaS 到 Agent 平台

3.1 护城河重塑：System of Record → Clearinghouse / Workflow

- **旧范式（SaaS 时代）**：护城河 = **记录系统（System of Record）**，"拥有数据即拥有护城河，数据有引力（data has gravity）"。
- **纠偏（"Workflows are King"）**："数据引力是真的，但**真正的护城河从来不是数据本身，而是围绕数据、真正把活干完的数百个工作流（workflows）**。"
- **新范式（Agents 时代）**：护城河迁移到 **清算中心（Clearinghouses）**——因为 **agentic 工作负载横跨多个记录系统**，单一 SoR 无法承载，需要一个"平台的平台（Platform of Platforms）"做跨系统编排与清算。

投资含义：传统单点 SaaS（单一 SoR）估值倍数面临压缩；能整合多 SoR、掌控跨系统工作流与 token/任务清算的平台层将获得**新的护城河溢价**。

3.2 基础设施卡位

(A) Databricks：从 Lakehouse 向 "Agentic AI 平台" 的演进（四合一：数据处理 + 数据 + agents + apps 平台）

- **KARL 模型（2026-03-06）**：在企业知识任务上**击败 Claude 4.6 与 GPT 5.2，成本低约 33%、延迟低约 47%**。方法论：用**合成数据上的强化学习（RL）**训练更小、更快、更省且任务表现更好的专用模型。战略意图：**闭环**——数据存储 → 检索 → 定制 RL agent 训练 → 服务，全在 Databricks 完成。
- **Genie Ontology（2026-06-16）**：后台构建企业知识图谱，用 "**OntoRank**"（**企业资产版 PageRank**）排序重要性；Databricks 自有实例已有 **450 万条 ontology snippets**。上层四个 agent：Genie One / Genie Agents / Genie Code / Genie Zero Ops（可在隔离分支修复凌晨 2 点的 pipeline 故障，一键审批）。
- **Unity AI Gateway**：所有 agent/模型的单一入口，承诺消费额度、跨云直购 OpenAI/Anthropic/Gemini token、预算告警、护栏审计、MCP 注册——卡位"AI 消费与治理的收费站"。
- **底层架构护城河**：Iceberg **v3 GA、v4（目标 2026 Q4）统一元数据**；Lakebase（湖上开源 Postgres，<1s 克隆 PB 级库）；**LTAP 统一事务与分析层（业界追逐 40 年的突破）**；Reyden 查询引擎（数十毫秒延迟）。

(B) ClickHouse：实时分析的第三极

- 2026-01-16：完成 \$400M D 轮，收购 Langfuse，推出 Postgres 产品。
- 2026-06-16：在 Databricks 官方 benchmark 中出现代表 ClickHouse 的"黄条"——数据仓库/湖仓之战从两强变三足。卡位逻辑："在 AI 与 agents 驱动的世界，实时是刚需"。

(C) Inngest：Loop Engineering 的循环工程卡位

- 范式宣言 (2026-07-01)："没人再做 prompting 了。全是写带目标函数的循环 (writing loops with goal functions)，然后去睡觉。"→ Loop Engineering。
- 运维痛点即市场 (2026-04-29)："20% 的 AI 团队把高达一半的工程时间花在维持系统运行上，是非 AI 团队的 2 倍。"直接量化了 durable/production-grade agent 编排层的 TAM。

(D) 配套主题：CPU 回归与存储重构

- CPU 回归 (2026-03-16)："Agents 将以惊人速率消耗 CPU 容量！"——利好通用算力。
- 存储重构：Nvidia 推出 "AI Data Platform" 参考架构 (12 家合作伙伴，含 Hammerspace)，把护城河从计算向存储/数据管线延伸。

3.3 信任层基建：ZKML 的必要性

Jamin 提出"每次平台迁移都需要对应的信任层"框架 (2026-04-02 / 01-31)：

平台迁移	对应信任层
互联网	SSL / TLS
移动	App Store 审核 + 沙箱
云	IAM + 零信任网络
Agentic（自动执行）时代	ZKML（零知识机器学习）

- 核心论点："很快我们就需要证明与我们通信对象的身份；零知识证明正走向 AI 领域。"
- 必要性逻辑：当 agent 开始自动执行有后果的任务（支付、交易、代表用户行动）时，需要能在不泄露模型/数据的前提下，密码学地证明"某个特定模型/权重确实执行了某次推理"。ZKML 是该验证层的强候选，是自动执行规模化的前置条件。

结论：投研主线与催化剂矩阵

主题	关键量化锚	受益标的	催化剂 / 风险
GPU 代际定价权	H100 \$2.30 → Blackwell >\$10/小时	\$NVDA	↑ 新架构租金溢价被市场验证；↓ Neocloud 90 天短约暴露需求脆弱性
云 AI 变现加速	GCP 34%→48%→63%；AWS 20%→24%→28%；Azure 约 39%	\$GOOG（弹性最大）、\$AMZN（修复）、\$MSFT（确定性）	↑ 万亿基数上同步加速；↓ 增速终将回落 + Capex 折旧压力
计费范式迁移	按小时 → 按 Token/credit	\$NVDA、推理优化层	卡入 token path 者定价权重估
成本断崖 → 需求放大	GLM5.2/Luna 混合 \$2/1M；效率每 8 月减半	全算力链（杰文斯效应）	需关注 token 效率而非单价
SaaS → Agent 平台	KARL 成本 -33% / 延迟 -47%；OntoRank 450 万 snippets	Databricks 、ClickHouse、Inngest	SoR 单点 SaaS 估值压缩
电力 = 新瓶颈	1GW \$50B→\$80—100B；5 年 \$7.5T 约 5—10% GDP	电力/HVDC 标的、并网领先的超大厂	↓ 数据中心禁令 = 系统性宏观风险

一句话主线： 算力周期的价值正沿着"更贵的芯片（Nvidia 定价权）→ 更快加速的云变现（GCP/AWS/Azure）→ 更便宜的 Token（杰文斯放大需求）→ 卡位跨系统清算的 Agent 平台（Databricks）→ 以电力与信任层（ZKML）为终极约束"这条链条重新分配。其中 Google Cloud 的增速弹性、Nvidia 的代际租金溢价、Databricks 的 agent 平台卡位是原文数据支撑最强的三个 alpha 来源，而 电力/信贷约束与数据中心政策风险是需要持续跟踪的系统性下行变量。

本报告基于 Jamin Ball 公开内容整理，仅供研究参考，不构成投资建议。